

# Support vector machine

---

Ngô Minh Nhật

Bộ môn Công nghệ Tri thức

2023

# Large margin classifier

---

Phần 1

# Hồi qui logistic

## □ Hypothesis:

- $h_{\theta}(x) = g(\theta^T x)$
- $h_{\theta}(x) = P(y = 1|x; \theta)$


$$g(z) = \frac{1}{1 + e^{-z}}$$

## □ $\theta^T x \gg 0$

- Khả năng  $y = 1$  càng cao


## □ $\theta^T x \ll 0$

- Khả năng  $y = 0$  càng cao



# Hồi qui logistic



## □ Margin



# Hồi qui logistic

□ Hàm chi phí cho một mẫu



$$-y \log \frac{1}{1 + e^{-\theta^T x}} - (1 - y) \log \left(1 - \frac{1}{1 + e^{-\theta^T x}}\right)$$



# Hồi qui logistic

□ Hàm chi phí cho một mẫu

$$-y \log \frac{1}{1 + e^{-\theta^T x}} - (1 - y) \log \left( 1 - \frac{1}{1 + e^{-\theta^T x}} \right)$$



# Support vector machine

---

## □ Hàm chi phí

$$J(\theta) = C \sum_{i=1}^m \left[ y^{(i)} \text{cost}_1(\theta^T x^{(i)}) + (1 - y^{(i)}) \text{cost}_0(\theta^T x^{(i)}) \right] + \frac{1}{2} \sum_{j=1}^n \theta_j^2$$

## □ Hồi qui logistic

$$J(\theta) = \frac{1}{m} \sum_{i=1}^m \left[ y^{(i)} (-\log h_{\theta}(x^{(i)})) + (1 - y^{(i)}) (-\log(1 - h_{\theta}(x^{(i)}))) \right] + \frac{\lambda}{2m} \sum_{j=1}^n \theta_j^2$$

# Mô hình SVM

---

## □ Hypothesis

- $y = 1$  if  $\theta^T x \geq 1$
- $y = 0$  if  $\theta^T x \leq -1$

## □ Hàm chi phí

$$J(\theta) = C \sum_{i=1}^m \left[ y^{(i)} \text{cost}_1(\theta^T x^{(i)}) + (1 - y^{(i)}) \text{cost}_0(\theta^T x^{(i)}) \right] + \frac{1}{2} \sum_{j=1}^n \theta_j^2$$

## □ Quá trình học:



$$\min_{\theta} J(\theta)$$



# Quá trình học

## □ Huấn luyện:

$$\min_{\theta} C \sum_{i=1}^m \left[ y^{(i)} \text{cost}_1(\theta^T x^{(i)}) + (1 - y^{(i)}) \text{cost}_0(\theta^T x^{(i)}) \right] + \frac{1}{2} \sum_{j=1}^n \theta_j^2$$



- Nếu  $y = 1$ , chúng ta cần  $\theta^T x \geq 1$
- Nếu  $y = 0$ , chúng ta cần  $\theta^T x \leq -1$

# Quá trình học

---

## □ Mục tiêu

$$\min_{\theta} C \sum_{i=1}^m \left[ y^{(i)} \text{cost}_1(\theta^T x^{(i)}) + (1 - y^{(i)}) \text{cost}_0(\theta^T x^{(i)}) \right] + \frac{1}{2} \sum_{j=1}^n \theta_j^2$$

- Nếu  $y = 1$ , chúng ta cần  $\theta^T x \geq 1$
- Nếu  $y = 0$ , chúng ta cần  $\theta^T x \leq -1$

$$\rightarrow \min_{\theta} \frac{1}{2} \sum_{j=1}^n \theta_j^2$$

$$\text{s.t.} \quad \theta^T x^{(i)} \geq 1 \quad \text{if} \quad y^{(i)} = 1$$

$$\theta^T x^{(i)} \leq -1 \quad \text{if} \quad y^{(i)} = 0$$

# Vì sao large margin

---

- ❑ Tích vô hướng

$$u = \begin{bmatrix} u_1 \\ u_2 \end{bmatrix}, \quad v = \begin{bmatrix} v_1 \\ v_2 \end{bmatrix}$$

$$u^T v = u_1 v_1 + u_2 v_2$$

- ❑ Độ lớn của vector  $u$ :  $\|u\| = \sqrt{u_1^2 + u_2^2}$

- ❑ Hình chiếu của  $v$  lên  $u$  có độ dài:  $p$

- ❑ Khi đó:

$$\begin{aligned} u^T v &= \|u\| \|v\| \cos \varphi \\ &= p \|u\| \end{aligned}$$

- $\varphi$  là góc giữa  $u$  và  $v$

# Vì sao large margin

---



$$\min_{\theta} \frac{1}{2} \sum_{j=1}^n \theta_j^2$$

$$\text{s.t. } \theta^T x^{(i)} \geq 1 \quad \text{if } y^{(i)} = 1$$

$$\theta^T x^{(i)} \leq -1 \quad \text{if } y^{(i)} = 0$$



Tích vô hướng:

$$\begin{aligned} \theta^T x^{(i)} &= p^{(i)} \|\theta\| \\ &= \theta_1 x_1^{(i)} + \theta_2 x_2^{(i)} \end{aligned}$$

# Vì sao large margin


---

$$\begin{aligned} \min_{\theta} \quad & \frac{1}{2} \sum_{j=1}^n \theta_j^2 \\ \text{s.t.} \quad & p^{(i)} \|\theta\| \geq 1 \quad \text{if } y^{(i)} = 1 \\ & p^{(i)} \|\theta\| \leq -1 \quad \text{if } y^{(i)} = 0 \end{aligned}$$


- Với  $p^{(i)}$  là độ dài hình chiếu của  $x^{(i)}$  lên  $\theta$
- $p^{(i)}$  là khoảng cách giữa mẫu tới đường phân lớp
- Do  $p^{(i)} \|\theta\| \geq 1$ 
  - $p^{(i)}$  càng nhỏ, độ dài  $\theta$  phải càng lớn
  - $p^{(i)}$  càng lớn, độ dài  $\theta$  có thể nhỏ

# Vì sao large margin

---



Narrow margin



Large margin


# Ánh xạ dữ liệu với Kernel

---

## Phần 2

# Phân lớp phi tuyến


- Bộ phân lớp tuyến tính hoạt động tốt trên dữ liệu phân tách tuyến tính



- Một số dữ liệu không phân tách tuyến tính




- Giải pháp: ánh xạ dữ liệu sang không gian cao chiều hơn





# Phân lớp phi tuyến

- Giải pháp: ánh xạ dữ liệu sang không gian cao chiều hơn



Ánh xạ dữ liệu được thực hiện như thế nào với SVM?

# Thuật toán học

---

$$\begin{aligned} \min_{\theta} \quad & \frac{1}{2} \sum_{j=1}^n \theta_j^2 \\ \text{s.t.} \quad & \theta^T x^{(i)} \geq 1 \quad \text{if } y^{(i)} = 1 \\ & \theta^T x^{(i)} \leq -1 \quad \text{if } y^{(i)} = 0 \end{aligned}$$

Đặt lại:  $y = -1$  cho lớp âm

$$\begin{aligned} \Rightarrow \min_{\theta} \quad & \frac{1}{2} \sum_{j=1}^n \theta_j^2 \\ \text{s.t.} \quad & y^{(i)} (\theta^T x^{(i)}) \geq 1, i = 1, 2, \dots, m \end{aligned}$$

# Thuật toán học

---

□ Đặt  $g_i(\theta) = -y^{(i)}(\theta^T x^{(i)}) + 1$

➔  $\min_{\theta} \frac{1}{2} \sum_{j=1}^n \theta_j^2$

s.t.  $g_i(\theta) = -y^{(i)}(\theta^T x^{(i)}) + 1 \leq 0$

Chuyển về bài toán nhân tử Lagrange:

$$\mathcal{L}(\theta, \alpha) = \frac{1}{2} \sum_{j=1}^n \theta_j^2 - \sum_{i=1}^m \alpha_i [y^{(i)}(\theta^T x^{(i)}) - 1]$$

Mục tiêu:  $\min_{\theta, \alpha} \mathcal{L}(\theta, \alpha)$

# Thuật toán học

---

$$\mathcal{L}(\theta, \alpha) = \frac{1}{2} \sum_{j=1}^n \theta_j^2 - \sum_{i=1}^m \alpha_i [y^{(i)} (\theta^T x^{(i)}) - 1]$$

Mục tiêu:  $\min_{\theta, \alpha} \mathcal{L}(\theta, \alpha)$

Điều kiện Karush-Kuhn-Tucker (KKT)

Giả sử:  $\theta^*, \alpha^*$  là nghiệm

- (1)  $\frac{\partial}{\partial \theta_j} \mathcal{L}(\theta^*, \alpha^*) = 0, j = 1, \dots, n$
- (2)  $\alpha_i^* g_i(\theta^*) = 0, i = 1, \dots, m$
- (3)  $g_i(\theta^*) \leq 0, i = 1, \dots, m$
- (4)  $\alpha_i^* \geq 0, i = 1, \dots, m$

# Thuật toán học

---

$$\mathcal{L}(\theta, \alpha) = \frac{1}{2} \sum_{j=1}^n \theta_j^2 - \sum_{i=1}^m \alpha_i [y^{(i)} (\theta^T x^{(i)}) - 1]$$

Mục tiêu:  $\min_{\theta, \alpha} \mathcal{L}(\theta, \alpha)$

Tìm theta:

$$(1) \quad \nabla_{\theta} \mathcal{L}(\theta, \alpha) = \theta - \sum_{i=1}^m \alpha_i y^{(i)} x^{(i)} = 0$$


$$\Rightarrow \theta = \sum_{i=1}^m \alpha_i y^{(i)} x^{(i)}$$

# Support vector

Điều kiện Karush-Kuhn-Tucker (KKT)

Giả sử:  $\theta^*, \alpha^*$  là nghiệm

- (1)  $\frac{\partial}{\partial \theta_j} \mathcal{L}(\theta^*, \alpha^*) = 0, j = 0, \dots, n$
- (2)  $\alpha_i^* g_i(\theta^*) = 0, i = 1, \dots, m$
- (3)  $g_i(\theta^*) \leq 0, i = 1, \dots, m$
- (4)  $\alpha_i^* \geq 0, i = 1, \dots, m$



Từ (2), (3), và (4):

if  $g_i(\theta^*) < 0$ , then  $\alpha_i^* = 0, i = 1, \dots, m$

Những mẫu nằm ngoài margin:  $\alpha_i^* = 0$


# Support vector

Những mẫu nằm ngoài margin:  $\alpha_i^* = 0$

$$\Rightarrow \theta = \sum_{i=1}^m \alpha_i y^{(i)} x^{(i)}$$

Predict:

$$\begin{aligned} \theta^T x &= \left( \sum_{i=1}^m \alpha_i y^{(i)} x^{(i)} \right)^T x \\ &= \sum_{i=1}^m \alpha_i y^{(i)} \langle x^{(i)}, x \rangle \end{aligned}$$



Chỉ cần tính với những điểm nằm trên margin  $\Rightarrow$  support vector

# Ánh xạ đặc trưng

---

## □ Predict

$$\begin{aligned}\theta^T x &= \left( \sum_{i=1}^m \alpha_i y^{(i)} x^{(i)} \right)^T x \\ &= \sum_{i=1}^m \alpha_i y^{(i)} \langle x^{(i)}, x \rangle\end{aligned}$$

- Có thể xem  $\langle x^{(i)}, x \rangle$  là độ giống nhau

## □ Định nghĩa hàm

$$\phi(x) = [x \quad x^2 \quad x^3]^T$$

Thay  $\langle x^{(i)}, x \rangle$  bằng  $\langle \phi(x^{(i)}), \phi(x) \rangle$



# Kernel

---

## □ Định nghĩa

$$K(x^{(i)}, x) = \langle \phi(x^{(i)}), \phi(x) \rangle$$

Predict:

$$\begin{aligned}\theta^T x &= \left( \sum_{i=1}^m \alpha_i y^{(i)} x^{(i)} \right)^T x \\ &= \sum_{i=1}^m \alpha_i y^{(i)} \langle x^{(i)}, x \rangle\end{aligned}$$


Thay  $\langle x^{(i)}, x \rangle$  bằng  $K(x^{(i)}, x)$

# Kernel

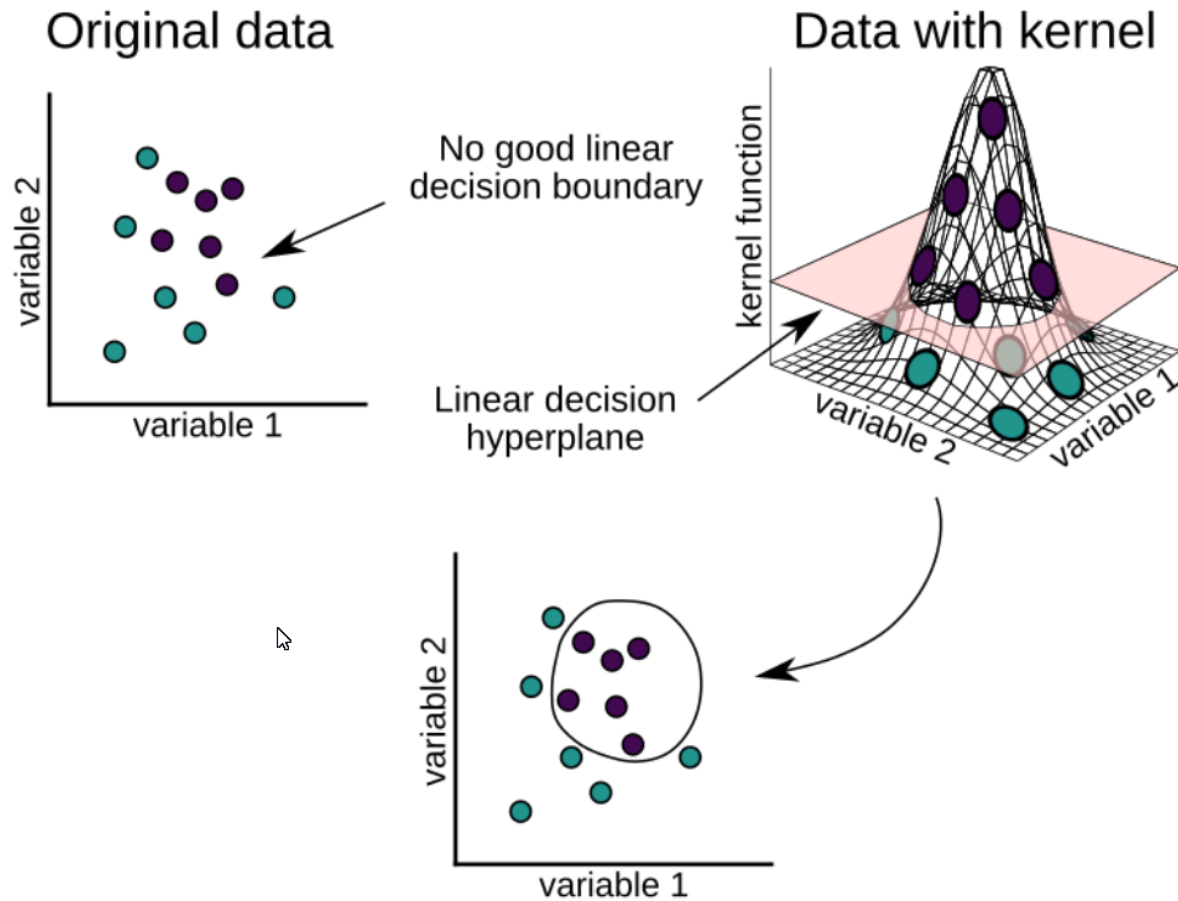
---

## □ Gaussian (RBF) kernel

$$K(x, z) = \exp\left(-\frac{\|x - z\|^2}{2\sigma^2}\right)$$




# Kernel



# Kernel

## □ Gaussian (RBF) kernel

$$K(x, z) = \exp\left(-\frac{\|x - z\|^2}{2\sigma^2}\right)$$



■  $\sigma$  càng lớn, độ lớn càng nhỏ

# Kernel

---

- Linear kernel

$$K(x, z) = x^T z$$

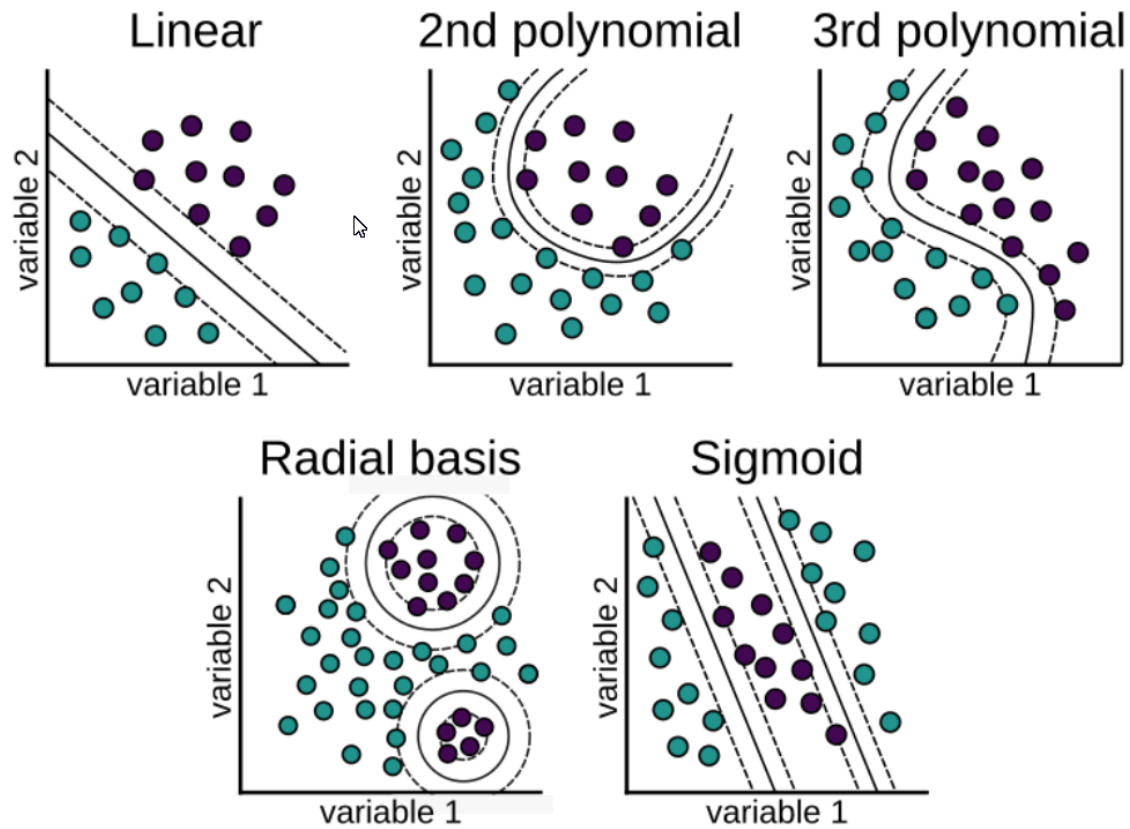
- Polynomial kernel

$$K(x, z) = (x^T z + c)^d$$

- Sigmoid kernel


$$K(x, z) = \tanh(ax^T z + b)$$

# Kernel



# SVM Playground

❑ <http://macheads101.com/demos/svm-playground>



# SVM Playground

❑ <http://macheads101.com/demos/svm-playground>

